

息，从而区分出物体的细微差异。高光谱图像有助于区分细微的光谱差异，其在众多领域都得到了广泛应用 (包括军事侦察、农业生产、环境监测、矿产勘查等诸多领域 [3-6])，如图 2 所示。

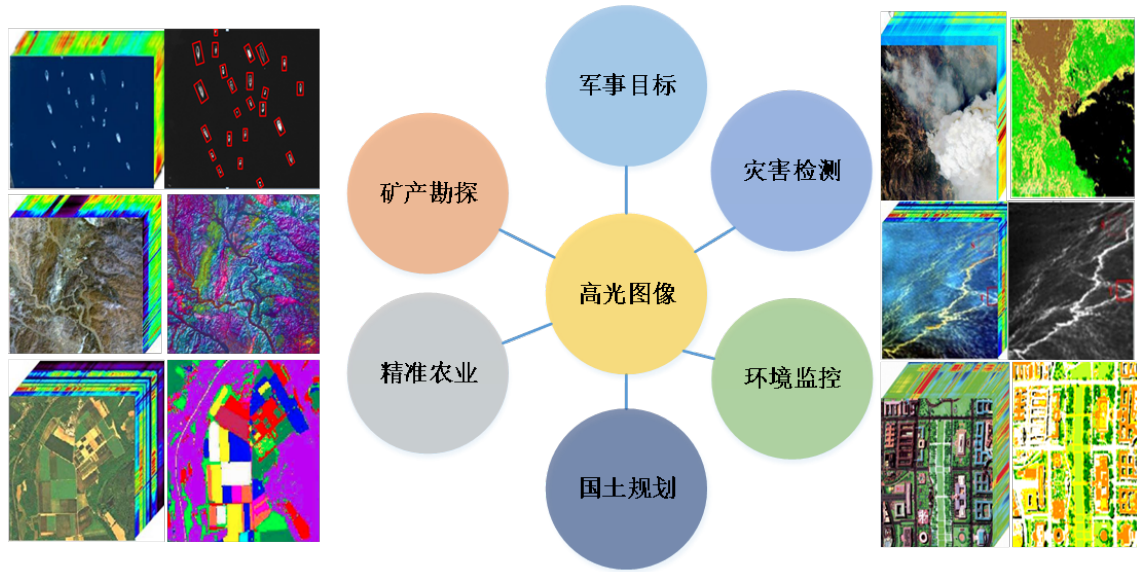


图 2. 高光谱图像多种领域应用

在高光谱图像分类领域，基于深度学习和其他方法的深度特征提取能力方面取得了极大的成功 [7]。由于在提取局部细节方面的优越性，基于卷积神经网络（CNN）的模型成为主流。刘 [8] 等人设计了一个双流 CNN，具有特征提取和融合架构，用于学习典型的土地覆盖分布。虽然 CNN 获得细粒度的特征，但全局的粗粒度信息难以捕获，并且特征提取不足。谢 [9] 等人提出了一个基于特征一致性的原型网络来收集独特的长距离地理属性，但非局部特征始终难以通过 CNN 捕获。许等人 [10] 集成了一个强大的自组装网络来协助网络训练。然而，大量的中间判别特征并未完全重用，导致了准确率的降低。刘等人 [11] 提出了一个中心关注网络来探索高光谱图像的内在属性，但是在这个配置中，光谱签名和空间特征被分开，使得有助于识别的基本特征未被合并且无法使用。洪等人 [12] 提出了一个通用的多模态深度学习框架，包含五种融合结构用于遥感分类。结果表明，特征类型，位置和集成方式对准确率改进有重大影响。杨等人 [13] 设计了一个增强的多尺度 CNN 用于光谱-空间特征提取。然而，当光谱和空间特征以简单的连接方式进行融合时，多领域的特征变化被埋没。基于 CNN 的方法擅长捕获局部细粒度特征，但仍然面临全局粗粒度信息的特征探索不足，代表性中间特征的重用缺乏，以及跨领域特征的非差异化融合。高光谱图像可以被视为序列数据，提出了基于循环神经网络 (RNN) 的方法来对高光谱图像进行分类 [14]。但在获取局部空间信息时失败，从而导致分类结果不准确。作为 RNN 的一种变体，引入了双向长短期记忆 (LSTM) 网络，以组成多尺度注意力 LSTM 神经网络进行多级特征提取 [15]。由于空间特征的不足，准确率并不高。在这个模型中，只有最后一层输出的特征被结合，导致底层和中层的有意义特征被遗漏。这些问题可以归因于模型的不完整性，即局部精细特征的丢失导致的部分特征未被充分探索，早期层次的重要特征未被充分利用，以及光谱和空间域特征没有得到合理的融合。

2 相关工作

在计算机视觉领域中 RGB 图像的特征提取技术已经被广泛应用于各类分类任务，展现出了卓越的性能。通过合理地结合高光谱图像数据的特性，构建一个包含以下三个核心元素的高光谱图像分类模型：全面特征探索、代表性特征重用以及多领域特征差异融合。首要元素是全面的特征探索，包括从每个光谱带中挖掘出精细的特征，自动从原始光谱数据中学习得到这些特征。其次是代表性特征的重用。由于不同光谱带的特征可能存在一定的重复或冗余。因此，通过深层神经网络可以有效地学习和提取出有代表性的特征，实现对特征的压缩和优化。最后是多领域特征差异的融合，采用特征融合的策略，将特定领域的特征与通用特征进行有效的融合，提高模型在特定分类任务上的适应性和准确性。

2.1 可用特征的广泛探索

HSI 提供了丰富的信息，为此全面建模局部 - 全局特征表示无疑是关键。在大部分现有方法中，局部细节与全局分布常常是不兼容的。CNN 和 Transformer 就各自领域而言，分别擅长提取局部感知和全局依赖性。同时获取局部精细特征和全局粗粒度信息，特征的可分离性得到了显著改善，类内距离缩小，类间间隙扩大，分类边界清晰，数据集的特征可视化如图 3 所示。




图 3. 数据集的特征可视化

2.2 重用代表性特征

现有的方法在对 HSI 进行分类时，常常只使用最后一层的特征，而忽视了从前几层获得的有价值的特征的交叉利用。这在一定程度上限制了精度的提升，且标注样本的稀缺性更是加剧了这个问题。一个简单而有效的策略就是充分的重用那些代表性的特征。

2.3 多领域特征的差异融合

大多数高级的光谱 - 空间分类方法对特征进行了简单的叠加或串联，不做区分地融合这些特征，从而产生了不恰当的特征表示。对多领域特征进行差异化融合是实现精确分类的最后一步，多领域特征的差异融合策略非常适合 HSI 的特定光谱和空间领域。

3 HSIC-FM 方法

在这个部分，详细的介绍所提出的 HSIC-FM，包括循环 transformer、特征复用策略和判别优化，框架如图 4 所示。

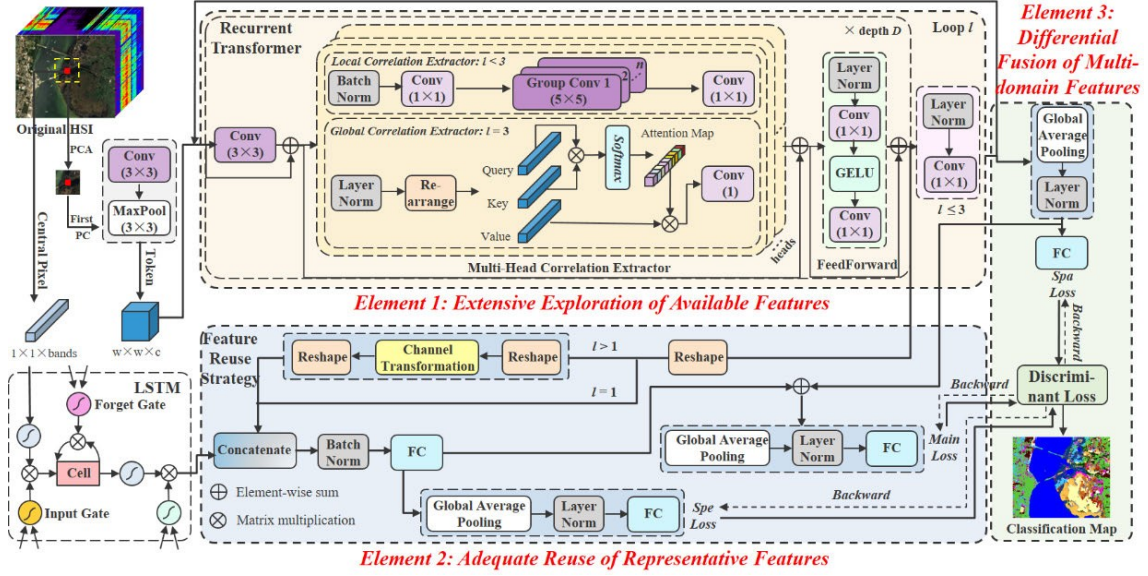


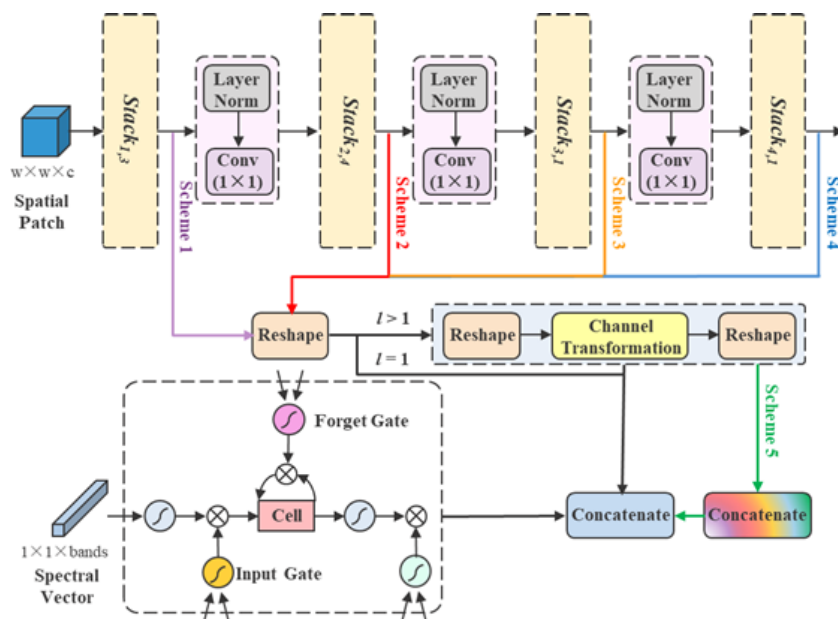
图 4. HSIC-FM 的框架图

3.1 循环 Transformer

高光谱图像是主成分分析（PCA）方法来降维，对于循环 transformer 灵活地卷积运算，自下而上的多样性循环中计算局部和全局关联，同时执行局部上下文学习和全球依赖性建模，提取浅层和深层特征信息。与普通的循环模型不同，所提出的循环 transformer 在每个循环中都包含不同的循环主体，循环 transformer 灵活地扩展了带卷积的 transformer。基于 CNN 和 transformer 的互补结构，可以产生细粒度和粗粒度的特征。因此，在所提出的循环 transformer 中，可用特征得到了广泛的探索。

3.2 特征复用策略

在高光谱图像分类中，特征复用策略主要分为两个部分，结构如图 5 所示。首先，选择重新利用堆叠结构中的特定特征。这些特征包含空间关联性以及显著性信息，通过重复使用这些特征可以加强有效的特征表示。对于采用所有特征的密集连接，重新利用一部分具有代表性的特征，这样不仅可以显著提升对有效特征的利用率，也能减少冗余计算。第二部分是考虑如何实现特征的重新使用。由于光谱向量会丢失邻域信息，需要引入额外的空间特征。空间特征对光谱特征提取提供深度指导，空间特征与光谱信号的相互作用也有助于提高精度。在高光谱图像分类过程中，从光谱向量中提取并融合的特征实现了特征的重复利用。特征重用策略对特征进行选择性的再利用，然后将其与光谱向量相结合。这种策略不仅能突出有效特征，抑制干扰和冗余，还能监督光谱域的特征提取，并生成光谱-空间跨领域特征，以确保充分利用具有代表性的特征。



3.3 判别优化

由于各个数据领域间存在差异,提出了一种判别损失,用以优化多领域特征的反向传播并实现其独特的特征融合。为了优化对应特征的提取,设计了光谱辅助损失、空间辅助损失和光谱-空间主损失,并通过判别损失来突出不同领域的贡献。通过改变权重,持续改进多领域特征的提取,从而达到满意、平衡和可靠的效果。基于深度学习的方法使用单一或非差异化的损失函数支持多领域的模型学习,这种方式往往会导致跨领域变化被掩盖。判别优化方法是简单而有效的方式量化这种差异,关注有利的特征。损失监控了光谱-空间联合分类任务,剩余的两个损失则限制次级的单一光谱或空间分类任务作为正则化项。高光谱图像中的多领域信息被有差异地融合,从而增强模型的个性化学习能力。基于循环 transformer、特征重用策略以及判别优化,建立了特征提取-重用-融合的一体化 HSIC-FM 模型,并实现了全面、精确且精细的分类结果。

4 复现细节

4.1 实验环境

采用的是 pytorch 的模型框架，主要的实验环境如下:libmr,numpy,scipy,tqdm matplotlib,pandas, Pytorch 1.9.0 和 Python 3.8。

4.2 实验指标

对于高光谱遥感图像而言, 仅仅从视觉的角度来评判分类模型的好坏往往是不合适的, 因此有必要引入一些评价指标对分类模型的优劣进行评判。在评价高光谱图像的分类效果时, 根据图像分类的混淆矩阵计算, 通过整体分类精度 (Overall Accuracy, OA), 平均分类精度 (Average Accuracy, AA) 还有 Kappa 系数三个评价指标计算得到^[10]。

4.3 数据集

使用公开的 Pavia University 数据集来验证所提出方法的有效性, 它们覆盖了农村、城市和农田场景, 对应的假彩色图和 GroundTruth 如图 6 所示。

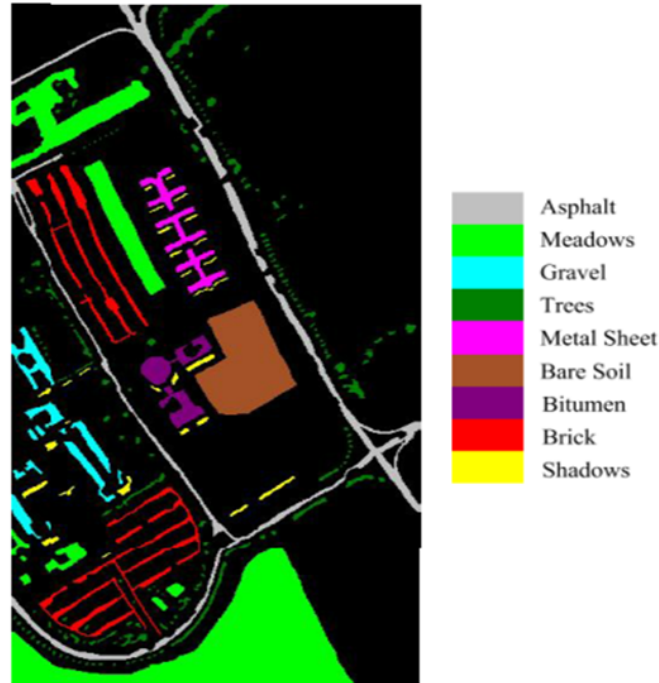


图 6. Pavia University 假彩色图和 Ground truth 图

1) Pavia University 数据集是在高光谱图像处理研究中广泛使用的公开数据集。这个数据集是由反射光学系统成像光谱仪 (ROSIS) 获取的, 收集地点位于意大利帕维亚一所大学附近。这个数据集包含 610×340 个像素点, 并具有 103 个不同的光谱波段 (原始数据共有 115 个波段, 但由于噪声等问题, 某些波段被剔除)。这些波段的波长范围涵盖了可见光到近红外光。Pavia University 数据集的一大特色是它涵盖了各种城市景观, 如道路、建筑物、屋顶和树木等, 每个样本的类名, 样本数量等信息如图 7 所示。










类别	类名	颜色	每类样本数量
1	Asphalt		6631
2	Meadows		18649
3	Graval		2099
4	Trees		3064
5	Metal Sheet		1345
6	Bare soil		5029
7	Bituen		1330
8	Bricks		3682
9	Shadows		947

图 7. Pavia University 数据集

4.4 实验细节

(1) 实验设置：为了全面地评估，选择了一台配备有 Intel(R) Core(TM)9-10900KF 3.70GHz CPU、Nvidia GTX 2080 TGPU 和 32GB RAM 的高性能计算机。该配置提供强大的并行计算能力和大量的内存空间，使得大规模数据的训练和测试。通过这项设置，旨在验证方法是否能有效地处理大规模的高光谱图像数据，来进一步验证提出的方法的优越性。

(2) 评价指标：对于高光谱遥感图像而言, 仅仅从视觉的角度来评判分类模型的好坏往往是不合适的，因此有必要引入一些评价指标对分类模型的优劣进行评判。在实验中，使用总体精度 (OA)、平均精度 (AA) 和 kappa 系数来评价不同分类方法的性能，并取均值和方差作为最终结果^[16]

5 实验分析

5.1 训练过程

在训练高光谱图像分类模型时，跟踪两种重要的指标：Accuracy（准确率）和 Loss（损失值），训练过程如图 8 所示。Accuracy Training (准确率训练) 是一个衡量模型预测能力好坏的指标，表示模型预测正确的样本数与总样本数的比例。在训练过程中，我们期望模型的准确率逐渐提高，以证明模型在学习并不断改善其预测性能。Loss Training (损失训练) 用于衡量模型预测值与实际目标值之间的差异。模型的损失值在训练过程中逐渐降低，直观上这表示模型预测的结果越来越接近真实的目标。




图 8. 训练重要指标

5.2 实验结果

在本小节中，复现的方法与其他几种先进的方法进行比较，包括 HSI-FM^[17], SSFT^[18] 和 VIT^[19] 分类模型。在这些方法中，具体的网络结构和参数设置可以在相应的参考文献中找到，本实验结果如图所示。

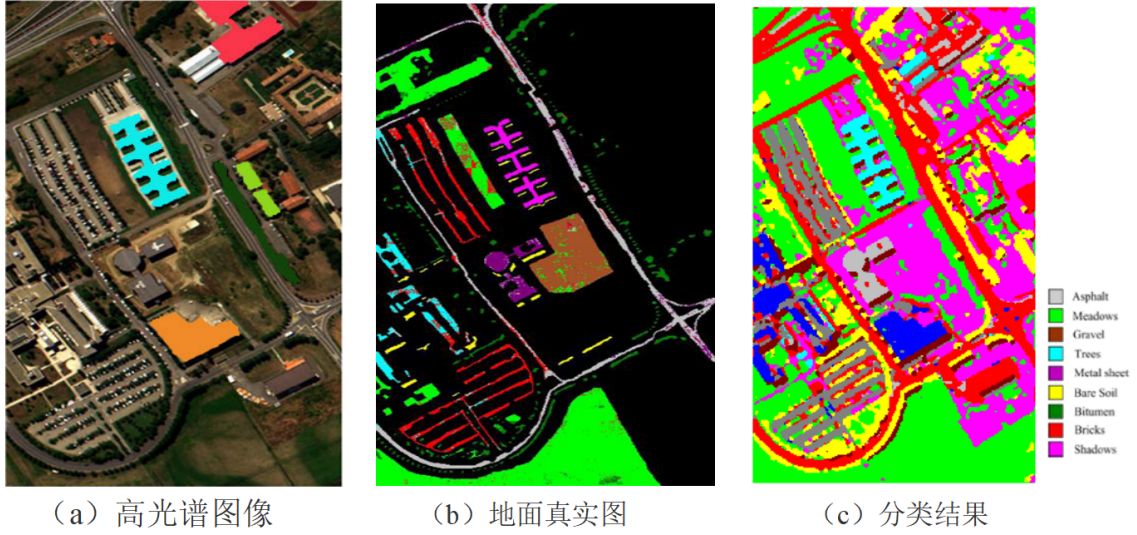


图 9. 在 Pavia University 获得的分类图

为了能够准确地比较实验结果，选择一些公认的评估标准来评价，使用总体精度 (OA)、平均精度 (AA) 和检测时间来进行对比实验，结果表 1 在 Pavia University 数据集的分类精度表明原始的高光谱图像分类模型存在一定的差异。

表 1. 在 Pavia University 数据集的分类精度

	OA	Kappa	Time
HSI-FM	94.40 \pm 0.68	92.62 \pm 0.87	0.38 + 0.17
Proposed	94.19 \pm 0.08	92.33 \pm 0.24	4.20 + 0.28
SSFT	88.53 \pm 2.11	84.92 \pm 2.67	4.81 + 0.61
VIT	67.52 \pm 1.78	58.67 \pm 2.01	110.72 + 330.09

6 总结与展望

针对高光谱图像分类的不完整性，复现了 HSIC-FM 模型。这个模型在高光谱图像分类时，提出了三个关键要素：全方位地探索可利用的特征，适当地重复使用有代表性的特征，以及汇聚来自不同领域特征的差异性。首先，提出了基于循环 Transformer 的模型，结合了本地上下文学习以及全局依赖性建模，让模型从底层至顶层都能获取到丰富信息。接着，通过特征重用策略，突出了那些具有代表性的特征，增加了模型对这些特征的依赖性。此外，将空间特征引入到光谱信号的深度学习中，形成一个光谱 - 空间联合信息的模式。最后，通过判别优化来区分多领域的贡献，并限制不同特征的影响力，以进一步优化反向传播过程。总的来说，构建了一个全面、详尽的高光谱图像分类特征模型，这种模型有效地处理了各种类型的特征，并将它们融合在一起。

在未来的研究中，探索如何在降低标注成本的同时实现全面分类。深度学习和其他各类机器学习任务中，标注数据集往往是一个繁杂且耗时的过程。因此，减少标记工作量成为一个有重要意义的研究领域。数据处理一种方法是引入弱监督技术，通过利用不完全、不确定或不准确的标签信息，大幅度减少手动标记的需求。另一个解决方案是使用粗粒度的标签来初步进行图像分类，通过更高级的模型对每个大类别中的样本进行细粒度特征提取和分类。

这种方法对图像进行粗略分类，然后逐步通过复杂的模型进行精细化处理。采用这些策略不仅能提升高光谱图像分类的准确率，还可以增强模型的鲁棒性，使其更具适应性和稳定性。

参考文献

- [1] Huang H , Yang M .Dimensionality Reduction of Hyperspectral Images With Sparse Discriminant Embedding[J].IEEE Transactions on Geoscience & Remote Sensing, 2015, 53(9):5160-5169.DOI:10.1109/TGRS.2015.2418203.
- [2] Du P , Xia J , Xue Z ,et al.Review of hyperspectral remote sensing image classification[J].Journal of Remote Sensing, 2016.DOI:10.11834/jrs.20165022.
- [3] KRUSE, F. A .Identification and mapping of minerals in drill core using hyperspectral image analysis of infrared reflectance spectra[J].International Journal of Remote Sensing, 1996, 17(9):1623-1632.DOI:10.1080/01431169608948728.
- [4] Lobo A , Garcia E , Barroso G ,et al.Machine Learning for Mineral Identification and Ore Estimation from Hyperspectral Imagery in Tin–Tungsten Deposits: Simulation under Indoor Conditions[J].Multidisciplinary Digital Publishing Institute, 2021(16).DOI:10.3390/RS13163258.
- [5] R. Li, s. Zheng, C. Duan, L. Wang, and C. Zhang, “Land coverclassification from remote sensing images based on multi-scale fullyconvolutional network,” *Geo-Spatial Inf Sci*, ol. 25, no. 2, pp. 1-172022,doi: 10.1080/10095020.2021.2017237
- [6] D. Wang, x. Chen, N. Guo, H. Yi, and Y. Li, “STCD: EfficientSiamese transformers-based change detection method for remote sensingimages,” *Geo-Spatial Inf Sci.*, vol. 2023, pp. 1-20, Jan. 2023, doi10.1080/10095020.2022.2157762.
- [7] J. Yang, B. Du, and L. Zhang, “From center to surrounding: An interactive learning framework for hyperspectral image classification,” *ISPRS J. Photogramm. Remote Sens.*, vol. 197, pp. 145–166, Mar. 2023, doi: 10.1016/j.isprsjprs.2023.01.024.
- [8] Q. Liu, L. Xiao, N. Huang, and J. Tang, “Composite neighbor-aware convolutional metric networks for hyperspectral image classification,” *IEEE Trans. Neural Netw. Learn. Syst.*, early access, Dec. 30, 2023, doi: 10.1109/TNNLS.2022.3232532.
- [9] Z. Xie, P. Duan, W. Liu, X. Kang, X. Wei, and S. Li, “Feature consistency-based prototype network for open-set hyperspectral image classification,” *IEEE Trans. Neural Netw. Learn. Syst.*, early access, Jan. 6, 2023, doi: 10.1109/TNNLS.2022.3232225
- [10] Y. Xu, B. Du, and L. Zhang, “Robust self-ensembling network for hyperspectral image classification,” *IEEE Trans. Neural Netw. Learn. Syst.*, early access, Aug. 19, 2022, doi: 10.1109/TNNLS.2022.3198142.

- [11] H. Liu, W. Li, X. Xia, M. Zhang, C. Gao, and R. Tao, “Central attention network for hyperspectral imagery classification,” *IEEE Trans. Neural Netw. Learn. Syst.*, early access, Mar. 10, 2022, doi:10.1109/TNNLS.2022.3155114.
- [12] D. Hong et al., “More diverse means better: Multimodal deep learning meets remote-sensing imagery classification,” *IEEE Trans. Geosci. Remote Sens.*, vol. 59, no. 5, pp. 4340–4354, May 2021, doi:10.1109/TGRS.2020.3016820.
- [13] Yang J , Wu C , Du B ,et al.Enhanced Multiscale Feature Fusion Network for HSI Classification[J].*IEEE Transactions on Geoscience and Remote Sensing*, 2021, PP(99):1-1.DOI:10.1109/TGRS.2020.3046757.
- [14] Zhou W ,Seiichiro-Kamata.Multi-Scanning Based Recurrent Neural Network for Hyper-spectral Image Classification[J]. 2021.DOI:10.1109/ICPR48806.2021.9413071.
- [15] H. Li, W. Hu, W. Li, J. Li, Q. Du, and A. Plaza, “A3 CLNN: Spatial, spectral and multiscale attention ConvLSTM neural network for multisource remote sensing data classification,” *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 33, no. 2, pp. 747–761, Feb. 2022, doi:10.1109/TNNLS.2020.3028945.
- [16] Feng, Hao,Wang, Yongcheng,Li, Zheng,et al.Information Leakage in Deep Learning-Based Hyperspectral Image Classification: A Survey[Z].*REMOTE SENSING*,2023,15(15).
- [17] J. Yang, B. Du and L. Zhang, ”Overcoming the Barrier of Incompleteness: A Hyperspectral Image Classification Full Model,” in *IEEE Transactions on Neural Networks and Learning Systems*, doi: 10.1109/TNNLS.2023.3279377.
- [18] Sun L , Zhao G , Zheng Y ,et al.Spectral–Spatial Feature Tokenization Transformer for Hyperspectral Image Classification[J].*IEEE Transactions on Geoscience and Remote Sensing*, 2022, 60.DOI:10.1109/TGRS.2022.3144158.
- [19] X. Chen, S. Kamata, and W. Zhou, “Hyperspectral image classification based on multi-stage vision transformer with stacked samples,” in *Proc. IEEE Region 10 Conf. (TENCON)*, Dec. 2021, pp. 441–446, doi: 10.1109/TENCON54134.2021.9707289.